



پروژه پایانی پایگاه داده پیشرفته

سلام!

به پروژه پایانی خوش آمدید.

در طول این ترم شما با تمرین‌ها و مثال‌های متنوعی مواجه شدید. به گونه‌ای که به صورت تدریجی توان تحلیل، طراحی و پیاده‌سازی شما در حوزه پایگاه داده و سیستم‌های داده محور تقویت شد.

و اما بالاخره رسیدید به مرحله آخر!

پروژه‌ای که در اون قراره طراحی و پیاده‌سازی یک پلتفرم کامل و کاربردی رو تجربه کنید:

پلتفرمی که از داده خام شروع میشه، به تحلیل و مصورسازی میرسه و در نهایت ویژگی جذاب پرسش و پاسخ هوشمند رو به اون اضافه خواهید کرد.

نکات بسیار مهم که حتما باید آن‌ها را مد نظر داشته باشید

- ارائه پروژه نهایی به صورت **آنلاین** انجام خواهد شد. در روز ارائه، شما موظف هستید برنامه خود را به طور زنده اجرا کنید و عملکرد صحیح آن را نمایش دهید. همچنین باید به سوالات دستیاران آموزشی پاسخ دقیق و مستند ارائه کنید. این فرآیند مستلزم درک عمیق از معماری، پیاده‌سازی و منطق درونی سیستم شماست. در صورتی که در جریان ارائه، توانایی توضیح کافی از بخش‌های متفاوت پروژه یا پاسخگویی به سوالات را نداشته باشید، **نمره پروژه شما به شدت کاهش خواهد یافت**، چرا که چنین وضعیتی نشان دهنده استفاده گسترده از ابزارهای هوش مصنوعی بدون درک کافی است.
- زبان برنامه نویسی و استفاده از تکنولوژی‌های نام برده در متن پروژه، همگی **پیشنهاد** است و شما میتوانید بر حسب نیاز پروژه، از ابزارها، فریم ورک‌ها و کتابخانه‌های دیگر نیز استفاده کنید.
- در بخش Text to SQL اصلا نیاز به استفاده از مدل‌های پولی **نیست**. شما میتوانید با مدل‌های رایگان که از طریق سایت OpenRouter یا هر سایت مشابه دیگر در دسترس است، پیاده‌سازی را انجام دهید.
- شما در این پروژه ترکیبی از مفاهیم دیتابیس، نرم افزار و مهندسی داده را تجربه خواهید کرد.
- داکيومنت نوشته شده توسط تمام دانشجویان **باید در حین توسعه سیستم** نوشته شود. هرگونه کلی گویی در نوشتار داکيومنت قابل قبول نخواهد بود و در متن داکيومنت، روند توسعه سیستم باید قابل مشاهده باشد.
- زمان پروژه، به دلیل محدودیت زمان وارد کردن نمرات از سوی آموزش دانشگاه، **به هیچ وجه تمدید نخواهد شد**، همانطور که در ابتدای ترم هم بیان شد، امکان استفاده از توکن‌ها برای پروژه پایانی وجود ندارد.
- پیاده‌سازی UI به سلیقه خود شما خواهد بود و استفاده از Streamlit، Gradio، React، Tailwind و کاملاً آزاد و به انتخاب شما خواهد بود.



پروژه پایانی پایگاه داده پیشرفته

پلتفرم هوشمند تحلیل داده‌های شرکت Uber

مرحله اول: آشنایی با دیتاست

در فایل ضمیمه، داده‌های واقعی تراکنش‌های شرکت Uber در سال 2024 قرار داده شده که شامل 148770 رکورد از انواع مختلف وسایل نقلیه است. قبل از هرگونه طراحی پایگاه داده، لازم است تا ساختار داده‌ها را با دقت بررسی کنید. لطفا موارد زیر را انجام دهید:

- توصیف کلی: درک کلی خود از دیتاست، مقیاس آن و حوزه کاربرد را بیان کنید.
 - معرفی ستون‌ها (Features): برای هر یک از ستون‌های موجود، دقیقا مشخص کنید که چه اطلاعاتی نگهداری می‌کند و نوع داده یا Data Type آن چیست.
 - ارتباطات منطقی: رابطه بین ستون‌ها را بر اساس منطق کسب و کار توضیح دهید.
- در پایان این مرحله شما باید درک کاملی از ماهیت هر ستون و نحوه پر شدن داده‌ها در دیتاست داشته باشید.

در ادامه بریم سراغ Medallion Architecture که به عنوان یک معماری به‌روز در حال استفاده است :





پروژه پایانی پایگاه داده پیشرفته

پلتفرم هوشمند تحلیل داده‌های شرکت Uber

مرحله دوم: طراحی معماری پایه بر اساس Bronze Architecture : لایه Bronze

لایه Bronze یا Raw Layer جایی است که داده‌ها دقیقاً همانطور که از منبع آمده‌اند، بدون هیچگونه تغییر ذخیره می‌شوند.

- در دیتابیس PostgreSQL (هر Relational Database مورد قبول است اما پیشنهاد ما PostgreSQL است) یک Schema جدید به نام bronze ایجاد کنید.
- یک جدول به نام raw_dataset بسازید.
- ستون‌های جدول را بر اساس تحلیلی که در مرحله اول انجام داده‌اید و با Data Type مناسب تعریف کنید و دیتاست اصلی را بدون تغییر، در جدول Import کنید.

نکته مهم آن است که هدف این مرحله Raw Ingestion است و صرفاً حفظ اصالت داده‌ها مدنظر است.

مرحله سوم: طراحی معماری پایه بر اساس Silver Architecture : لایه Silver

در این فاز، باید عملیات ETL را انجام دهید تا داده‌ها برای تحلیل آماده شوند. خروجی این مرحله باید در جدولی با نام silver.cleaned_dataset ذخیره شود.

اقدام اول: مهندسی ویژگی (Feature Engineering)

- بررسی کنید آیا فرمت تاریخ و ساعت استاندارد است؟
- با نظر خودتان می‌توانید یک ستون جدید برای استخراج جزئیات زمان یا تاریخ اضافه کنید. دلیل خود را برای این کار بیان کنید.
- با بررسی کامل دیتاست، تحلیل کنید که آیا با اضافه کردن ستون‌های جدید، می‌توان ستون‌های قدیمی را حذف کرد؟

اقدام دوم: یکپارچه‌سازی دلایل لغو سفر

- سه ستون مختلف شامل دلایل لغو توسط راننده، مشتری یا سفر ناقص وجود دارد. یک ستون جدید به نام Unified_cancellation_reason ایجاد کنید.
- با توجه به ستون Booking Status دلیل لغو صحیح را از یکی از سه ستون برداشته و در ستون جدید ذخیره کنید.

اقدام سوم: مدیریت مقادیر Null

- بررسی کنید کدام ستون‌ها حجم زیادی از مقادیر Null دارند. آیا حذف این ردیف‌ها منطقی است؟ راهکار شما برای مدیریت این حجم Null چیست؟

اقدام چهارم: تحلیل و مدیریت امتیازها

- ستون‌های Driver Ratings و Customer Rating را بررسی کنید. Null بودن این مقادیر همیشه به معنی ناقص بودن داده‌ها نیست. برای وضعیت‌های مختلف بررسی کنید که Null بودن امتیاز چه معنایی دارد؟
- در سفرهای Completed بررسی کنید رفتار مشتریان و رانندگان برای ثبت امتیاز چگونه بوده است؟
- آیا با داده‌های موجود می‌توانیم برای Customer Rating و سفرهای تکمیل شده چاره‌ای بیندیشیم تا از حجم Null بودن کم کنیم؟ دقت کنید که از حذف ردیف‌ها به دلیل نبودن امتیاز خودداری کنید!



پروژه پایانی پایگاه داده پیشرفته

پلتفرم هوشمند تحلیل داده‌های شرکت Uber

مرحله چهارم: طراحی معماری پایه بر اساس Medallion Architecture : لایه Gold
لایه Gold، لایه نهایی و قابل اتکا برای تحلیل کسب و کار و تولید گزارشات است. داده‌ها در این لایه باید بهینه‌سازی شده، غنی و آماده خواندن سریع باشند.

اقدام اول: طراحی نهایی Schema:
○ جدول نهایی خود را با نام gold.dataset ایجاد کنید. از انواع داده دقیق و بهینه استفاده کنید.

اقدام دوم: محاسبه و غنی سازی داده‌ها:
○ یک ستون جدید محاسباتی اضافه کنید. به عنوان مثال، revenue_per_km حاصل تقسیم Booking Value بر Ride Distance است. (حتما به مقادیر صفر و Null دقت کنید)

اقدام سوم: یکپارچگی داده
○ این جدول باید دارای Primary Key باشد.
○ از محدودیت CHECK برای اطمینان از صحت داده‌ها استفاده کنید. مثلا اطمینان حاصل کنید که امتیازات داده شده بین 0 تا 5 است

در پایان این مرحله، شما باید یک جدول واحد داشته باشید که تمیزترین و آماده‌ترین نسخه داده‌های Uber را برای فرآیندهای بعدی نگهداری می‌کند.

مرحله پنجم: پیاده سازی CRUD API
در این مرحله، باید پلی میان کاربر و دیتابیس ایجاد کنید. شما می‌توانید با هر زبانی یا فریم‌ورکی که به آن تسلط دارید، مانند Go، Django، FastAPI، Node JS و ... این پیاده سازی را انجام دهید.
هدف اصلی این مرحله، انجام عملیات CRUD روی لایه Gold است. نیازی به سیستم احراز هویت پیچیده نیست.

اندپوینت های زیر را پیاده سازی کنید:
• ساخت سفر جدید (Create): دریافت اطلاعات تاریخ، زمان، نوع خودرو و روش پرداخت و امتیاز از کاربر. دقت بفرمایید که فرض کنید وضعیت سفر Completed است و Booking ID باید به صورت خودکار تولید شود.

• لیست سفرها (Read): نمایش لیستی از سفرها با قابلیت فیلتر بر اساس Customer ID

• تغییر وضعیت (Update): در صورت بروز مشکل یا تغییر برنامه، امکان تغییر وضعیت سفر باید فراهم باشد.

• حذف (Delete): امکان حذف یک رکورد سفر از دیتابیس

برای نمایش عملیات CRUD، از Streamlit استفاده کنید. اگر تمایل دارید می‌توانید از React یا دیگر ابزارها مانند Gradio نیز استفاده کنید. اما توصیه می‌کنیم از پیچیده‌سازی بیهوده UI خودداری کنید.



پروژه پایانی پایگاه داده پیشرفته

پلتفرم هوشمند تحلیل داده‌های شرکت Uber

مرحله ششم: داشبور تحلیلی و تعاملی

در این مرحله با استفاده از Streamlit یا ابزارهای مشابه، یک داشبورد تعاملی بسازید که وضعیت کسب و کار را به تصویر بکشد.

اقدام اول: شاخص‌های کلیدی عملکرد (KPIs)

- تعداد کل رزروها
- تعداد کل رزروهای موفق
- مجموع درآمد
- نرخ موفقیت سفر

اقدام دوم: نمودارها

- نمودار Pie Chart برای نمایش درصد یا توزیع دلایل لغو سفر و نمایش درصد استفاده از روش‌های مختلف پرداخت
- نمودار Bar Chart برای مقایسه تعداد سفرهای انجام شده برای هر نوع خودرو و نمایش میانگین امتیاز مشتری یا راننده به تکفیک خودرو
- نمودار خطی برای نمایش ساعت‌های پر تردد و روزهای هفته بر اساس تعداد سفر

اقدام سوم: تعاملی بودن

- داشبورد باید دارای فیلترهای انتخاب بازه زمانی و انتخاب نوع خودرو باشد
- با تغییر فیلترها، تمام شاخص‌ها و نمودارها باید به روز رسانی شوند.





پروژه پایانی پایگاه داده پیشرفته

پلتفرم هوشمند تحلیل داده‌های شرکت Uber

مرحله هفتم: دستیار هوشمند Text to SQL

در این قسمت شما باید یک رابط کاربری چت بسازید که بتواند سوالات مدیران را به زبان **انگلیسی** دریافت کرده و پاسخ آن را از دیتابیس استخراج کند. مهم است بدانید که هوش مصنوعی به تنهایی دسترسی به دیتابیس شما ندارد.

معماری Workflow که باید پیاده سازی کنید:

- ورودی : سوال متنی کاربر به زبان انگلیسی

- تولید SQL توسط AI: شما سوال را به همراه اطلاعات ساختار جدول Gold به مدل زبانی می‌دهید. مدل زبانی فقط یک متن برمی‌گرداند که کد SQL است.

- اعتبارسنجی و فیلتر: کد شما باید خروجی مدل را قبل از اجرا بررسی کند:
 - دستورات مخرب مانند DELETE، UPDATE، DROP و INSERT باید بلاک شوند.
 - الگوهای خطرناک مانند SELECT * FROM بدون LIMIT باید بلاک شوند.
 - برای جلوگیری از سنگین شدن، اگر کوئری بدون LIMIT بود، LIMIT 10 را به آن اضافه کنید.
 - اگر کاربر سوالی بجز حوزه کاربرد این چت بات پرسید (سوالاتی مثل کد زدن، احوال پرس و ...) نباید پاسخ داده شود.

- اجرا: اگر کوئری از نظر امنیتی تایید شد، کد شما آن کوئری را روی دیتابیس اجرا می‌کند و نتیجه کوئری به کاربر نمایش داده خواهد شد.

الزامات فنی:

- برای مدل‌های هوش مصنوعی از API‌های رایگان که توسط OpenRouter یا Groq داده می‌شود استفاده کنید و اصلاً نیاز به خرید API نیست.

- مدل‌هایی مانند CodeLlama یا SQLCoder در Hugging Face در دسترس هستند اما نیاز به پیچیده کردن فرایند نیست.

- انتخاب مدل و فریم‌ورک پیاده سازی مانند LangChain یا LangGraph به عهده خود شماست.

- برای اینکه مدل بتواند کوئری درست بنویسد، شما باید Schema Injection انجام دهید که منطبق با جدول Gold شما خواهد بود.

- سیستم شما فقط باید به درخواست‌های SELECT پاسخ دهد.

- از قوانین توسعه نرم‌افزار بهره ببرید، به طور مثال API را مستقیماً در کد قرار ندهید. پیشنهاد می‌کنم API را در فایل env. قرار دهید و آن را در فایل gitignore اضافه کنید تا از Push شدن آن در GitHub جلوگیری شود.



پروژه پایانی پایگاه داده پیشرفته

پلتفرم هوشمند تحلیل داده‌های شرکت Uber

مرحله هشتم: بهینه سازی و ایندکس گذاری

در این مرحله باید به صورت عملی تاثیر ایندکس گذاری بر بهبود عملکرد دیتابیس را بسنجید.

اقدام اول: انتخاب و نوشتن کوئری سنگین

- یک کوئری SELECT بنویسید که شامل فیلترهای ترکیبی یا عملیات Aggregation باشد. این کوئری باید طوری طراحی شود که دیتابیس ناچار باشد حجم زیادی از داده‌ها را بررسی کند تا اثر ایندکس واضح شود.

اقدام دوم: قبل از ایجاد ایندکس

- قبل از ایجاد ایندکس، کوئری را روی جدول Gold اجرا کنید.
- از دستور EXPLAIN ANALYZE استفاده کنید تا زمان اجرای واقعی و پلن اجرایی را مشاهده کنید. اسکرین شات خروجی را ذخیره کنید.

اقدام سوم: ایندکس گذاری

- با توجه به شناختی که در مرحله اول از دیتاست خود کسب کرده‌اید، یک یا چند ایندکس مناسب بسازید. ممکن است لازم باشد از Composite Index استفاده کنید.
- دلیل انتخاب ستون‌های ایندکس و نوع ایندکس گذاری خود را باید به صورت تکنیکال توجیه کنید.
- مجدداً همان کوئری دقیق را اجرا کنید و خروجی را تحلیل کنید و اسکرین شات بگیرید.

اقدام سوم: تحلیل نتیجه

- زمان اجرا را قبل و بعد از ایندکس گذاری مقایسه کنید.
- به صورت کلی تحلیل خود درباره پلن اجرایی را هم بیان کنید.



پروژه پایانی پایگاه داده پیشرفته

پلتفرم هوشمند تحلیل داده‌های شرکت Uber

مرحله نهم: پیاده سازی Vector Database و جستجوی معنایی (Semantic Search)
در معماری مدرن نرم‌افزار، به جای استفاده از یک دیتابیس، از دیتابیس‌های چندزبانه (Polyglot Persistence) استفاده می‌شود. در این مرحله، شما باید یک دیتابیس برداری (Vector Database) را به پروژه اضافه کنید تا قابلیت جستجوی معنایی روی دلایل لغو سفر ایجاد کنید.

هدف آن است که سیستم شما باید بتواند، دلایل شکست سفر را پیدا کند.

- اقدام اول: انتخاب ابزار و طراحی دیتابیس برداری**
- از Chroma DB که می‌تواند روی سیستم لوکال شما اجرا شود، استفاده کنید.
 - ستون Unified_cancellation_reason که در مرحله سوم ساختید را به همراه Booking ID در Collection در Chroma DB وارد کنید.
 - باید بدانید که Chroma DB از Embedding Model پیش فرض خود برای تبدیل متن به بردار استفاده می‌کند. مگر اینکه مدل دیگری مشخص شود.

- اقدام دوم: پیاده‌سازی اندپوینت جستجو :**
- در API و UI خود، یک بخش جستجو جدید بسازید که یک عبارت متنی درباره علت کنسل شدن سفرها از کاربر دریافت کند.
 - این عبارت را در Chroma DB جستجو کنید تا ۵ مورد ($Top_k = 5$) که بیشترین شباهت معنایی را دارند، برگرداند.
 - سیستم باید از شناسه‌های سفر (Booking ID) که از Chroma دریافت کرده، برای واکنشی جزئیات کامل (شامل قیمت، مسافت، امتیاز و...) از جدول gold.dataset در PostgreSQL استفاده کند.
 - نتیجه نهایی (جزئیات کامل ۵ سفر) را به کاربر نمایش دهید.



پروژه پایانی پایگاه داده پیشرفته

تحويل پروژه:

- لینک ریزیتوری گیت‌هاب جهت بررسی کدهای پروژه
- داکيومنت کامل پروژه
- بقیه موارد در جلسه آنلاین ارائه بررسی خواهد شد

زمان تحويل پروژه : 19 بهمن - February 8
زمان ارائه‌های آنلاین : 20 و 21 بهمن

دکتر محمد علی نعمت بخش
علی معینیان - بهنام صوفی